



山東財經大學

Shandong University of Finance and Economics

| 计算机科学与技术学院

School of Computer Science and Technology

MACHINE
LEARNING

机器学习



第三章：线性模型

第三章：线性模型

1. 线性回归

- 线性回归、多元线性回归

2. 二分类任务

- 广义线性回归、线性判别分析

3. 多分类任务

4. 类别不平衡问题

第三章：线性模型

重点

- 线性回归
- 线性判别分析
- 类别不平衡问题

难点

- 线性回归求解：最小二乘法
- 线性判别分析

第三章：线性模型

线性回归

- 线性模型、分线性模型
- 线性回归 及其求解（最小二乘法）
- 多元线性回归

二分类任务

多分类任务

类别不平衡问题

线性模型

线性模型

$$f(x) = \omega_1 x_1 + \omega_2 x_2 + \dots + \omega_d x_d + b$$

例子

□ 综合考虑色泽、根蒂和敲声，来判断西瓜好不好

$$f_{\text{好瓜}}(x) = 0.2 \cdot x_{\text{色泽}} + 0.5 \cdot x_{\text{根蒂}} + 0.3 \cdot x_{\text{敲声}} + 1$$

- 根蒂的系数最大，表明根蒂最要紧
- 敲声的系数比色泽大，说明敲声比色泽更重要

线性模型

线性模型

$$f(x) = \omega_1 x_1 + \omega_2 x_2 + \dots + \omega_d x_d + b$$

向量形式

$$f(\mathbf{x}) = \boldsymbol{\omega}^T \mathbf{x} + b$$

其中, $\mathbf{x} = (x_1, x_2, \dots, x_d)$, $\boldsymbol{\omega} = (\omega_1, \omega_2, \dots, \omega_d)$

- 综合考虑色泽、根蒂和敲声, 来判断西瓜好不好

$$f_{\text{好瓜}}(\mathbf{x}) = 0.2 \cdot x_{\text{色泽}} + 0.5 \cdot x_{\text{根蒂}} + 0.3 \cdot x_{\text{敲声}} + 1$$

$$\mathbf{x} = (x_{\text{色泽}}, x_{\text{根蒂}}, x_{\text{敲声}}), \quad \boldsymbol{\omega} = (0.2, 0.5, 0.3), \quad b = 1$$

线性模型

线性模型 $f(x) = \omega^T x + b$

优点

- 形式简单、易于建模
- 可解释性
 - ω 直观表达了 各属性在预测中的重要性
 - 线性模型有很好的可解释性

非线性模型

线性模型

$$f(\mathbf{x}) = \omega^T \mathbf{x} + b$$

非线性模型的基础

- 在线性模型的基础上，引入层级结构或高维映射，构成非线性模型

非线性模型

线性模型 $f(x) = \omega^T x + b$

非线性模型的基础



- 在线性模型的基础上，引入层级结构或高维映射，构成非线性模型
- 非线性模型 可以转换为 线性模型

二次多项式 $ax^2 + bx + c = (mx + p)(nx + q)$

e.g. $6x^2 + 17x + 5 = (2x + 5)(3x + 1)$

指数函数 $e^x = 1 + \frac{x}{1!} + \frac{x^2}{2!} + \frac{x^3}{3!} + \dots + \frac{x^n}{n!}$

非线性模型

线性模型 $f(x) = \omega^T x + b$

非线性模型的基础

- 在线性模型的基础上，引入层级结构或高维映射，构成非线性模型
- 非线性模型 可以转换为 线性模型

泰勒公式

$$f(x) = \frac{f(a)}{0!} + \frac{f'(a)}{1!} (x - a) + \frac{f''(a)}{2!} (x - a)^2 + \dots + \frac{f^{(n)}(a)}{n!} (x - a)^n$$

线性回归

□ 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$,

其中 $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$, $y_i \in \mathbf{R}$

离散属性处理

◆ 样本 x 的属性值间, 存在 有“序”关系

◆ 样本 x 的属性值间, 存在 无“序”关系

线性回归

□ 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$,

其中 $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$, $y_i \in \mathbb{R}$

离散属性处理

◆ 样本 x 的属性值间, 存在 有“序”关系

- 通过连续化, 将其转化为连续值

e.g. 二值属性“身高”的高、矮 可转化为 $\{1, 0\}$

◆ 样本 x 的属性值间, 存在 无“序”关系

线性回归

□ 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$,

其中 $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$, $y_i \in \mathbb{R}$

离散属性处理

◆ 样本 x 的属性值间, 存在 有“序”关系

- 通过连续化, 将其转化为连续值

e.g. 二值属性“身高”的高、矮 可转化为 $\{1, 0\}$

◆ 样本 x 的属性值间, 存在 无“序”关系

- 有 k 个属性值, 则转换为 k 维向量

e.g. “瓜类”的取值“西瓜、南瓜、黄瓜”可转化为 $\{0, 0, 1\}, \{0, 1, 0\}, \{1, 0, 0\}$

线性回归

□ 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$,

其中 $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$, $y_i \in \mathbf{R}$

线性回归 目的

□ 学得一个线性模型 $f(\mathbf{x}) = \omega^T \mathbf{x} + b$

➤ 离散

➤ 连续

线性回归

□ 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$,

其中 $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$, $y_i \in \mathbf{R}$

线性回归 目的

□ 学得一个线性模型 $f(\mathbf{x}) = \omega^T \mathbf{x} + b$

➤ 离散：以尽可能准确地 预测 真实输出标记 y ，即

$$f(\mathbf{x}) \cong y$$

➤ 连续

线性回归

□ 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$,

其中 $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$, $y_i \in \mathbb{R}$

线性回归 目的

□ 学得一个线性模型 $f(\mathbf{x}) = \omega^T \mathbf{x} + b$

➤ 离散：以尽可能准确地 预测 真实输出标记 y ，即

$$f(\mathbf{x}) \cong y$$

➤ 连续：预测输出 $f(\mathbf{x})$ 与真实输出 y 的偏差尽可能小

$$\min (f(\mathbf{x}) - y)^2$$

线性回归 目标

$f(\mathbf{x}) = \omega^T \mathbf{x} + b$ 使得 $f(\mathbf{x}) \cong y$ 或 $\min (f(\mathbf{x}) - y)^2$

线性回归

线性回归 目标

$f(x) = \omega^T x + b$ 使得 $f(x) \approx y$ 或 $\min (f(x) - y)^2$

单一、连续 属性 参数/模型 估计：最小二乘法

线性回归

线性回归 目标

$f(x) = \omega^T x + b$ 使得 $f(x) \approx y$ 或 $\min (f(x) - y)^2$

单一、连续 属性 参数/模型 估计：最小二乘法

□ 目标 $\min (f(x) - y)^2$

线性回归

线性回归 目标

$f(x) = \omega^T x + b$ 使得 $f(x) \approx y$ 或 $\min (f(x) - y)^2$

单一、连续 属性 参数/模型 估计：最小二乘法

□ 目标 $\min (f(x) - y)^2$

- m 个样本，只有一个属性 x ，目标：

$$\min \sum_{i=1}^m (f(x_i) - y_i)^2 = \min \sum_{i=1}^m (y_i - \omega x_i - b)^2$$

线性回归

线性回归 目标

$f(x) = \omega^T x + b$ 使得 $f(x) \approx y$ 或 $\min (f(x) - y)^2$

单一、连续 属性 参数/模型 估计：最小二乘法

□ 目标 $\min (f(x) - y)^2$

- m 个样本，只有一个属性 x ，目标：

$$\min \sum_{i=1}^m (f(x_i) - y_i)^2 = \min \sum_{i=1}^m (y_i - \omega x_i - b)^2$$

- 试图找到一条直线，使所有样本(m个) 到直线上的欧氏距离之和最小

线性回归

线性回归 目标

$f(x) = \omega^T x + b$ 使得 $f(x) \approx y$ 或 $\min (f(x) - y)^2$

单一、连续 属性 参数/模型 估计：最小二乘法

□ 目标 $\min (f(x) - y)^2$

- m 个样本，只有一个属性 x ，目标：

$$\min \sum_{i=1}^m (f(x_i) - y_i)^2 = \min \sum_{i=1}^m (y_i - \omega x_i - b)^2$$

- 试图找到一条直线，使所有样本(m个) 到直线上的欧氏距离之和最小

➤ 目标：最小化均方误差 $E_{(\omega, b)} = \sum_{i=1}^m (y_i - \omega x_i - b)^2$

$$\begin{aligned} (\omega^*, b^*) &= \arg \min_{(\omega, b)} \sum_{i=1}^m (f(x_i) - y_i)^2 \\ &= \arg \min_{(\omega, b)} \sum_{i=1}^m (y_i - \omega x_i - b)^2 \end{aligned}$$

线性回归

线性回归 目标

$f(x) = \omega^T x + b$ 使得 $f(x) \approx y$ 或 $\min (f(x) - y)^2$

单一、连续 属性 参数/模型 估计：最小二乘法

□ 目标 $\min (f(x) - y)^2$

$$(\omega^*, b^*) = \arg \min_{(\omega, b)} \sum_{i=1}^m (y_i - \omega x_i - b)^2$$

线性回归

线性回归 目标

$f(x) = \omega^T x + b$ 使得 $f(x) \approx y$ 或 $\min (f(x) - y)^2$

单一、连续 属性 参数/模型 估计：最小二乘法

□ 目标 $\min (f(x) - y)^2$

$$(\omega^*, b^*) = \arg \min_{(\omega, b)} \sum_{i=1}^m (y_i - \omega x_i - b)^2$$

- 训练样本 仅为 全部样本的 一个小的采样
无法求得 $E_{(\omega, b)}$ 最小值
只能求得 $E_{(\omega, b)}$ 的极小值，即 $E_{(\omega, b)}$ 一阶导数为 0

线性回归

线性回归 目标

$f(x) = \omega^T x + b$ 使得 $f(x) \approx y$ 或 $\min (f(x) - y)^2$

单一、连续 属性 参数/模型 估计：最小二乘法

□ 目标 $\min (f(x) - y)^2$

$$(\omega^*, b^*) = \arg \min_{(\omega, b)} \sum_{i=1}^m (y_i - \omega x_i - b)^2$$

求 $E_{(\omega, b)}$ 的极小值，即 $E_{(\omega, b)}$ 一阶导数为 0

线性回归

线性回归 目标

$f(x) = \omega^T x + b$ 使得 $f(x) \approx y$ 或 $\min (f(x) - y)^2$

单一、连续 属性 参数/模型 估计：最小二乘法

□ 目标 $\min (f(x) - y)^2$

$$(\omega^*, b^*) = \arg \min_{(\omega, b)} \sum_{i=1}^m (y_i - \omega x_i - b)^2$$

求 $E_{(\omega, b)}$ 的极小值，即 $E_{(\omega, b)}$ 一阶导数为 0

- 分别对 ω 和 b 求一阶导，令其等于 0 可得到 ω 和 b 最优解的闭式解

$$\frac{\partial E_{(\omega, b)}}{\partial \omega} = 2 \left(\omega \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) \cdot x_i \right) = 0$$

$$\frac{\partial E_{(\omega, b)}}{\partial b} = 2 \left(mb - \sum_{i=1}^m (y_i - \omega x_i) \right) = 0$$

线性回归

线性回归 目标

$f(x) = \omega^T x + b$ 使得 $f(x) \approx y$ 或 $\min (f(x) - y)^2$

单一、连续 属性 参数/模型 估计：最小二乘法

□ 目标 $\min (f(x) - y)^2$

$$(\omega^*, b^*) = \arg \min_{(\omega, b)} \sum_{i=1}^m (y_i - \omega x_i - b)^2$$

求 $E_{(\omega, b)}$ 的极小值，即 $E_{(\omega, b)}$ 一阶导数为 0

- 分别对 ω 和 b 求一阶导，令其等于 0 可得到 ω 和 b 最优解的闭式解：

$$\omega = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} (\sum_{i=1}^m x_i)^2} \quad b = \frac{1}{m} \sum_{i=1}^m (y_i - \omega x_i)$$

$$\text{其中, } \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

第三章：线性模型

1. 线性回归

- 线性回归
- 多元线性回归

2. 二分类任务

- 广义线性回归、线性判别分析

3. 多分类任务

4. 类别不平衡问题

多元线性回归

□ 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$,

其中 $\mathbf{x} = (x_{i1}; x_{i2}; \dots; x_{id})$, $y_i \in \mathbf{R}$

多元线性回归 目标

□ 对于任意的 x_i 满足 $f(x) = \omega x_i + b$ 使得 $f(x) \cong y_i$

多元线性回归

□ 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$,

其中 $\mathbf{x} = (x_{i1}; x_{i2}; \dots; x_{id})$, $y_i \in \mathbf{R}$

多元线性回归 目标

□ 对于任意的 x_i 满足 $f(\mathbf{x}) = \omega x_i + b$ 使得 $f(\mathbf{x}) \approx y_i$

◆ 数据集 D

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^T & 1 \\ \mathbf{x}_2^T & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^T & 1 \end{pmatrix}$$

其中, 矩阵 \mathbf{X} 大小 $m \times (d + 1)$

每行对应于一个示例 (样本), 该行前 d 个元素对应于示例的 d 个属性值, 最后一个元素恒置为 1。

多元线性回归

□ 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$,

其中 $\mathbf{x} = (x_{i1}; x_{i2}; \dots; x_{id})$, $y_i \in \mathbf{R}$

多元线性回归 目标

□ 对于任意的 x_i 满足 $f(\mathbf{x}) = \omega \mathbf{x} + b$ 使得 $f(\mathbf{x}) \approx y_i$

◆ 数据集 D

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^T & 1 \\ \mathbf{x}_2^T & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^T & 1 \end{pmatrix}$$

◆ 把 ω 和 b 吸收入向量形式 $\hat{\omega}^* = (\omega, b)$

◆ 标记 表示为向量形式 $\mathbf{y} = (y_1; y_2; \dots; y_m)$

多元线性回归

多元线性回归 目标 $f(x) = \omega^T X + b$ 使得 $f(x) \approx y$

参数/模型 估计：最小二乘法

□ 最小二乘法 估计 ω 和 b

$$\hat{\omega}^* = \arg \min_{\hat{\omega}} (\mathbf{y} - \mathbf{X}\hat{\omega})^T (\mathbf{y} - \mathbf{X}\hat{\omega})$$

令 $E_{\hat{\omega}} = (\mathbf{y} - \mathbf{X}\hat{\omega})^T (\mathbf{y} - \mathbf{X}\hat{\omega})$, 对 $\hat{\omega}$ 求导, 令其等于0

$$\frac{\partial E_{\hat{\omega}}}{\partial \hat{\omega}} = 2\mathbf{X}^T (\mathbf{X}\hat{\omega} - \mathbf{y}) = 0$$

多元线性回归

多元线性回归 目标 $f(x) = \omega^T X + b$ 使得 $f(x) \approx y$

参数/模型 估计：最小二乘法

□ 最小二乘法 估计 ω 和 b

$$\hat{\omega}^* = \arg \min_{\hat{\omega}} (\mathbf{y} - \mathbf{X}\hat{\omega})^T (\mathbf{y} - \mathbf{X}\hat{\omega})$$

$$\frac{\partial E_{\hat{\omega}}}{\partial \hat{\omega}} = 2\mathbf{X}^T (\mathbf{X}\hat{\omega} - \mathbf{y}) = 0$$

多元线性回归

多元线性回归 目标 $f(x) = \omega^T X + b$ 使得 $f(x) \approx y$

参数/模型 估计：最小二乘法

□ 最小二乘法 估计 ω 和 b

$$\hat{\omega}^* = \arg \min_{\hat{\omega}} (y - X\hat{\omega})^T (y - X\hat{\omega})$$

$$\frac{\partial E_{\hat{\omega}}}{\partial \hat{\omega}} = 2X^T(X\hat{\omega} - y) = 0$$

■ $\hat{\omega}^*$ 最优解的闭式解

➤ $X^T X$ 是 满秩矩阵或正定矩阵

➤ $X^T X$ 不是 满秩矩阵

多元线性回归

多元线性回归 目标 $f(x) = \omega^T X + b$ 使得 $f(x) \approx y$

参数/模型 估计：最小二乘法

□ 最小二乘法 估计 ω 和 b

$$\hat{\omega}^* = \arg \min_{\hat{\omega}} (y - X\hat{\omega})^T (y - X\hat{\omega})$$

$$\frac{\partial E_{\hat{\omega}}}{\partial \hat{\omega}} = 2X^T(X\hat{\omega} - y) = 0$$

■ $\hat{\omega}^*$ 最优解的闭式解

➤ $X^T X$ 是 满秩矩阵或正定矩阵，则

- $\hat{\omega}^* = (X^T X)^{-1} X^T y$
- 线性回归模型为 $f(\hat{x}_i) = \hat{x}_i^T (X^T X)^{-1} X^T y$

多元线性回归

多元线性回归 目标 $f(x) = \omega^T X + b$ 使得 $f(x) \approx y$

参数/模型 估计：最小二乘法

□ **最小二乘法 估计 ω 和 b**

$$\hat{\omega}^* = \arg \min_{\hat{\omega}} (y - X\hat{\omega})^T (y - X\hat{\omega})$$


$$\frac{\partial E_{\hat{\omega}}}{\partial \hat{\omega}} = 2X^T(X\hat{\omega} - y) = 0$$

■ $\hat{\omega}^*$ 最优解的闭式解


➤ **$X^T X$ 不是 满秩矩阵**

- 例如，在许多任务中我们会遇到大量的变量，其数目甚至超过样本数，导致 X 的列数多于行数， $X^T X$ 显然不满秩。
- 此时，可解出多个 ω ，均能使均方误差最小化。
 - ✓ 选择哪一个解作为输出？
 - ✓ 归纳偏好选择解 (1.4节)、引入正则化 (6.4、11.4节)


正则化



欠拟合
高偏差



恰好



过拟合
高方差


考虑如下一般形式的损失函数：

$$w^* = \arg \min_w \sum L(y_i, f(x_i; w)) + \lambda \Omega(w)$$

我们既要让训练误差（上式第一项）最小，又想让模型尽可能地简单（上式第二项）。

正则化

我们有个朴素的想法：那就让权重 W 多几个为0（或者接近于0，说明该节点影响很小）不就好了，相当于在神经网络中删掉了一些节点，这样模型就变简单了。



正则化


为了让 \mathbf{W} 多几个为0，对于我们的正则化项 $\Omega(\mathbf{W})$, 定义如下3种范数：

- **L0范数**: $\|\mathbf{w}\|_0$, 指向量中非0的元素的个数，越小说明0元素越多
- **L1范数**: $\|\mathbf{w}\|_1$, 指向量中各个元素绝对值之和
- **L2范数**: $\|\mathbf{w}\|_2$, 即各元素的平方和再开方

$$\|\mathbf{x}\|_1 = \sum_{i=1}^N |x_i| , \quad \|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^N x_i^2} ,$$

正则化

$$\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \sum_{j=1}^M |w_j|^q$$



上图中，可以明显看到一个趋势，即 q 越小，曲线越贴近坐标轴^Q， q 越大，曲线越远离坐标轴，并且棱角越明显。那么 $q=0$ 和 $q=\infty$ 时极限情况如何呢？猜猜看。

正则化

- 线性回归+L1正则项: **Lasso** 回归
- 线性回归+L2正则项: **Ridge** 回归 (岭回归)
- 如果我们用L0范数来正则化一个参数矩阵W的话, 就是希望W的大部分元素都是0, 让参数W是**稀疏**的, “压缩感知”、“稀疏编码”就是通过L0来实现的
- **L1范数是L0范数的最优凸近似**, 而且它比L0范数要容易优化

求解

$$\begin{aligned} \min \|x\|_0 \\ \text{s.t. } Ax = b \end{aligned}$$

在一定条件下, 以
概率1意义下等价



$$\begin{aligned} \min \|x\|_1 \\ \text{s.t. } Ax = b \end{aligned}$$

正则化

- ◆ **特征选择**: x_i 的大部分元素（也就是特征）都是和最终的输出 y_i 没有关系或者不提供任何信息的；但在预测新的样本时，这些没用的信息反而会被考虑，从而干扰了对正确 y_i 的预测。稀疏规则化算子的引入就是为了完成**特征自动选择**的光荣使命，它会学习地去掉这些没有信息的特征，也就是把这些特征对应的**权重置为0**。
- ◆ **可解释性**: 患病回归模型 $y = w_1 * x_1 + w_2 * x_2 + \dots + w_{1000} * x_{1000} + b$ ，通过学习，如果最后学习到的 w^* 就只有很少的非零元素，例如只有5个非零的 w_i 。也就是说，患不患这种病只和这5个因素有关，那医生就好分析多了。

第三章：线性模型

1. 线性回归

- 线性回归、多元线性回归

2. 二分类任务

- 广义线性回归

单位跃阶函数、对数线性回归、对数几率回归

- 线性判别分析

3. 多分类任务

4. 类别不平衡问题

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \equiv y$

- $g(\cdot)$: 联系函数, 单调可微函数

将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T \mathbf{x} + b)$ $y = \{0, 1\}$ $f(\mathbf{x}) \cong y$

$g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(\mathbf{x}) = \omega^T \mathbf{x} + b$ 联系起来

□ $g(\cdot)$ 最理想的函数为单位跃阶函数, $y = \begin{cases} 0 & z < 0 \\ 0.5 & z = 0 \\ 1 & z > 0 \end{cases}$

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T \mathbf{x} + b)$ $y = \{0, 1\}$ $f(\mathbf{x}) \equiv y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(\mathbf{x}) = \omega^T \mathbf{x} + b$ 联系起来

□ $g(\cdot)$ 最理想的函数为单位跃阶函数, $y = \begin{cases} 0 & z < 0 \\ 0.5 & z = 0 \\ 1 & z > 0 \end{cases}$

□ $g(\cdot) = \ln(y)$, 对数函数, 为对数线性回归

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T \mathbf{x} + b)$ $y = \{0, 1\}$ $f(\mathbf{x}) \equiv y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(\mathbf{x}) = \omega^T \mathbf{x} + b$ 联系起来

□ $g(\cdot)$ 最理想的函数为单位跃阶函数, $y = \begin{cases} 0 & z < 0 \\ 0.5 & z = 0 \\ 1 & z > 0 \end{cases}$

□ $g(\cdot) = \ln(y)$, 对数函数, 为对数线性回归

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率函数, 为对数几率回归

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T \mathbf{x} + b)$ $y = \{0, 1\}$ $f(\mathbf{x}) \equiv y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(\mathbf{x}) = \omega^T \mathbf{x} + b$ 联系起来

□ $g(\cdot)$ 最理想的函数为 **单位跃阶函数**

$$y = \begin{cases} 0 & z < 0 \text{ 即 } \omega^T \mathbf{x} + b < 0 \\ 0.5 & z = 0 \text{ 即 } \omega^T \mathbf{x} + b = 0 \\ 1 & z > 0 \text{ 即 } \omega^T \mathbf{x} + b > 0 \end{cases}$$

- 预测值 $z > 0$, 即 $\omega^T \mathbf{x} + b > 0$, 判为 **正例** $y = \{1\}$
预测值 $z < 0$, 即 $\omega^T \mathbf{x} + b < 0$, 判为 **反例** $y = \{0\}$
预测值 $z = 0$, 即 $\omega^T \mathbf{x} + b = 0$ **临界值**, 则可任意判别

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T \mathbf{x} + b)$ $y = \{0, 1\}$ $f(\mathbf{x}) \equiv y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(\mathbf{x}) = \omega^T \mathbf{x} + b$ 联系起来

□ $g(\cdot)$ 最理想的函数为 **单位跃阶函数**

$$y = \begin{cases} 0 & z < 0 \text{ 即 } \omega^T \mathbf{x} + b < 0 \\ 0.5 & z = 0 \text{ 即 } \omega^T \mathbf{x} + b = 0 \\ 1 & z > 0 \text{ 即 } \omega^T \mathbf{x} + b > 0 \end{cases}$$

- 预测值 $z > 0$, 即 $\omega^T \mathbf{x} + b > 0$, 判为 **正例** $y = \{1\}$
预测值 $z < 0$, 即 $\omega^T \mathbf{x} + b < 0$, 判为 **反例** $y = \{0\}$
预测值 $z = 0$, 即 $\omega^T \mathbf{x} + b = 0$ **临界值**, 则可**任意判别**
- **缺点**: 不连续, 不能直接用作 $g^{-1}(\omega^T \mathbf{x} + b)$ 中的 $g^{-1}()$


广义线性模型 解 二分类

广义 线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \cong y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln(y)$, 对数线性回归

$$\begin{aligned} y &= e^{\omega^T x + b} \\ \updownarrow \\ \ln y &= \omega^T x + b \end{aligned}$$




广义线性模型 解 二分类

广义 线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \approx y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln(y)$, 对数线性回归

$$\begin{array}{c} y = e^{\omega^T x + b} \\ \updownarrow \\ \ln y = \omega^T x + b \end{array}$$



- 用线性回归模型的预测结果

$f(x) = \omega^T x + b$ 逼近 真实标记 y 的对数 $\ln(y)$, $y = e^{\omega^T x + b}$

- 实质上, 是在求取输入空间到输出空间的非线性函数映射。

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \cong y$

$g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归

$$y = \frac{1}{1 + e^{-(\omega^T x + b)}} \longleftrightarrow \ln \frac{y}{1-y} = \omega^T x + b$$

◆ 线性回归的预测结果 $f(x) = \omega^T x + b$ 逼近 真实标记 y 的对数几率

$$y = \frac{1}{1 + e^{-z}} \longrightarrow y = \frac{1}{1 + e^{-(\omega^T x + b)}}$$

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \cong y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归

$$y = \frac{1}{1 + e^{-(\omega^T x + b)}}$$



$$\ln \frac{y}{1-y} = \omega^T x + b$$

◆ 线性回归的预测结果 $f(x) = \omega^T x + b$ 逼近 真实标记 y 的对数几率

$$y = \frac{1}{1 + e^{-z}} \quad \longrightarrow \quad y = \frac{1}{1 + e^{-(\omega^T x + b)}}$$

◆ 对应的模型称为“对数几率回归” (logistic regression)

➤ 注意：虽然它的名字是“回归”，实际是一种分类学习方法

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \cong y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归


◆ 线性回归的预测结果 $f(x) = \omega^T x + b$ 逼近 真实标记 y 的对数几率

$$y = \frac{1}{1+e^{-z}} \longrightarrow y = \frac{1}{1+e^{-(\omega^T x + b)}}$$

特点

- 单调可微、任意阶可导
- 将 $z = f(x)$ 值转化为一个接近 0 或 1 的 y 值
- 输出值在 $z = f(x) = 0$ 附近变化很陡

单位阶跃函数 VS 对数几率函数



广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \equiv y$

$g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归

◆ 物理含义

- y : 样本 x 作为正例的可能性
- $1-y$: 样本 x 是反例的可能性
- 对数几率 $\ln \frac{y}{1-y}$ 描述了样本 x 作为正例的相对可能性

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \cong y$

$g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归

◆ 对数几率 $\ln \frac{y}{1-y}$ 描述了 样本 作为 正例 的相对可能性

$$\ln \frac{y}{1-y} = \omega^T x + b \quad \Rightarrow \quad \ln \frac{P(y = 1|x)}{P(y = 0|x)} = \omega^T x + b$$

$$\Rightarrow \begin{cases} P(y = 1|x) = \frac{e^{\omega^T x + b}}{1 + e^{\omega^T x + b}} \\ P(y = 0|x) = \frac{1}{1 + e^{\omega^T x + b}} \end{cases}$$

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \cong y$

$g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归

样本为正例的相对可能性

$$\text{即 } \ln \frac{P(y=1|x)}{P(y=0|x)} = \omega^T x + b \implies P(y=1|x) = \frac{e^{\omega^T x + b}}{1 + e^{\omega^T x + b}}$$

◆ 求解: 极大似然法 $f(x) \cong y \rightarrow$ 估计 ω 和 b , 数据集 $\{(x_i, y_i)\}_{i=1, \dots, m}$

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \approx y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归

样本为正例的相对可能性

$$\text{即 } \ln \frac{P(y=1|x)}{P(y=0|x)} = \omega^T x + b \implies P(y=1|x) = \frac{e^{\omega^T x + b}}{1 + e^{\omega^T x + b}}$$

◆ 求解: 极大似然法 $f(x) \approx y \rightarrow$ 估计 ω 和 b , 数据集 $\{(x_i, y_i)\}_{i=1, \dots, m}$

目标函数: 最大化 样本标记属于其真实标记 的概率

即 $\max P\{\text{样本标记} \subset \text{真实标记}\}$ 或 $\min P\{\text{样本错误标记}\}$

• 最大化 对数似然函数 $\ell(\omega, b) = \sum_{i=1}^m \ln p(y_i | x_i; \omega_i, b)$

即 每个样本标记属于其真实标记的概率越大越好

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \cong y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归

样本为正例的相对可能性

$$\text{即 } \ln \frac{P(y=1|x)}{P(y=0|x)} = \omega^T x + b \implies P(y=1|x) = \frac{e^{\omega^T x + b}}{1 + e^{\omega^T x + b}}$$

◆ 求解: 极大似然法 $f(x) \cong y \rightarrow$ 估计 ω 和 b , 数据集 $\{(x_i, y_i)\}_{i=1, \dots, m}$

目标函数: 最大化 样本标记属于其真实标记 的概率

• 最大化 对数似然函数 $\ell(\omega, b) = \sum_{i=1}^m \ln p(y_i | x_i; \omega_i, b)$

求解: 凸优化理论中的数值优化算法, 如梯度下降法、牛顿法

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T \mathbf{x} + b)$ $y = \{0, 1\}$ $f(\mathbf{x}) \approx y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(\mathbf{x}) = \omega^T \mathbf{x} + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归

◆ 线性回归 $f(\mathbf{x}) = \omega^T \mathbf{x} + b$ 逼近 真实标记 y 的对数几率

◆ 对数几率描述了：样本作为 正例 的相对可能性

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \cong y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归

◆ 线性回归 $f(x) = \omega^T x + b$ 逼近 真实标记 y 的对数几率

◆ 对数几率描述了：样本作为 正例 的相对可能性

◆ 优点

- 直接对分类可能性进行建模，无需事先假设数据分布，避免了假设分布不准确所带来的问题

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T \mathbf{x} + b)$ $y = \{0, 1\}$ $f(\mathbf{x}) \cong y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(\mathbf{x}) = \omega^T \mathbf{x} + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归

◆ 线性回归 $f(\mathbf{x}) = \omega^T \mathbf{x} + b$ 逼近 真实标记 y 的对数几率

◆ 对数几率 描述了：样本作为 正例 的相对可能性

◆ 优点

- 不仅预测出“类别”，且可得到“类别”的近似概率预测，对许多需利用概率辅助决策的任务很有用。

广义线性模型 解 二分类

广义线性模型

□ 一般形式 $y = g^{-1}(\omega^T x + b)$ $y = \{0, 1\}$ $f(x) \cong y$
 $g(\cdot)$ 将分类标记 y 与线性回归输出 $z = f(x) = \omega^T x + b$ 联系起来

□ $g(\cdot) = \ln \frac{y}{1-y}$, 对数几率回归

◆ 线性回归 $f(x) = \omega^T x + b$ 逼近 真实标记 y 的对数几率

◆ 对数几率 描述了：样本作为 正例 的相对可能性

◆ 优点

- 对数几率函数，是任意阶可导的凸函数，可直接应用现有数值优化算法求取最优解

第三章：线性模型

1. 线性回归

- 线性回归、多元线性回归

2. 二分类任务

- 广义线性回归

单位跃阶函数、对数线性回归、对数几率回归

- 线性判别分析

3. 多分类任务

4. 类别不平衡问题

线性判别分析 LDA

线性判别分析

- **Linear Discriminant Analysis, LDA**
- 经典的线性学习方法，最早由[Fisher, 1936] 提出，称Fisher 判别分析

线性判别分析 LDA

线性判别分析

- ◆ 给定训练样本集，设法将样本投影到一条直线上，使得
 - 同类样本的投影点，尽可能接近
 - 异类样本的投影点，尽可能远离

线性判别分析 LDA


线性判别分析

◆ 给定**训练样本集**，设法将样本投影到一条直线上，使得

- **同类**样本的投影点，尽可能**接近**
- **异类**样本的投影点，尽可能**远离**

◆ 对**新样本**进行分类时，

- 将新样本投影到同样的这条直线上
- 根据投影点的位置确定新样本的类别



◆ **LDA**可视为监督降维技术，求解二分类问题

线性判别分析 LDA

LDA 思想

- ◆ 同类样本的投影点，尽可能接近
 - 投影点的协方差尽可能小
 - 协方差矩阵 Σ_i 尽可能小
- ◆ 异类样本的投影点，尽可能远离
 - 类中心之间的距离，尽可能大
 - 异类样本的均值向量 μ_i 之间的距离尽可能大

线性判别分析 LDA

LDA 思想

- ◆ 同类样本接近，协方差矩阵 Σ_i 尽可能小
- ◆ 异类样本远离，均值向量 μ_i 尽可能大

线性判别分析 LDA

LDA 思想

- ◆ 同类样本接近，协方差矩阵 Σ_i 尽可能小
- ◆ 异类样本远离，均值向量 μ_i 尽可能大

□ 一些变量

- 第 i 类样本的集合 X_i
- 第 i 类样本的均值向量 μ_i
- 第 i 类样本的协方差矩阵 Σ_i
- 两类样本中心在直线上的投影： $\omega^T \mu_0$ 和 $\omega^T \mu_1$
- 两类样本在直线上的投影的协方差： $\omega^T \Sigma_0 \omega$ 和 $\omega^T \Sigma_1 \omega$

线性判别分析 LDA

同类样本接近，协方差矩阵 Σ_i 尽可能小

- 最小化类内散度矩阵

$$S_{\omega} = \Sigma_0 + \Sigma_1 = \sum_{x \in X_0} (x - \mu_0)(x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1)(x - \mu_1)^T$$

线性判别分析 LDA

同类样本接近，协方差矩阵 Σ_i 尽可能小

- 最小化类内散度矩阵

$$S_{\omega} = \Sigma_0 + \Sigma_1 = \sum_{x \in X_0} (x - \mu_0)(x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1)(x - \mu_1)^T$$

异类样本远离，均值向量 μ_i 尽可能大

- 最大化类间散度矩阵

$$S_b = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T$$

线性判别分析 LDA

同类样本接近，协方差矩阵 Σ_i 尽可能小

- 最小化类内散度矩阵

$$S_w = \Sigma_0 + \Sigma_1 = \sum_{x \in X_0} (x - \mu_0)(x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1)(x - \mu_1)^T$$

异类样本远离，均值向量 μ_i 尽可能大

- 最大化类间散度矩阵

$$S_b = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T$$

最大化 广义瑞利商

$$J = \frac{\omega^T S_b \omega}{\omega^T S_w \omega} = \frac{\omega^T (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T \omega}{\omega^T (\Sigma_0 + \Sigma_1) \omega}$$

线性判别分析 LDA

LDA 求解多分类任务

同类样本接近，协方差矩阵 Σ_i 尽可能小

异类样本远离，均值向量 μ_i 尽可能大

线性判别分析 LDA

LDA 求解多分类任务

同类样本接近，协方差矩阵 Σ_i 尽可能小

- 最小化每个类别内散度矩阵

$$S_{\omega} = \sum_{i=1}^N S_{\omega_i} \quad S_{\omega_i} = \sum_{x \in X_i} (x - \mu_i)(x - \mu_i)^T$$

线性判别分析 LDA

LDA 求解多分类任务

同类样本接近，协方差矩阵 Σ_i 尽可能小

- 最小化每个类别内散度矩阵

$$S_{\omega} = \sum_{i=1}^N S_{\omega_i} \quad S_{\omega_i} = \sum_{x \in X_i} (x - \mu_i)(x - \mu_i)^T$$

异类样本远离，均值向量 μ_i 尽可能大

- 最大化不同类别间散度矩阵

$$S_b = S_t - S_{\omega} = \sum_{i=1}^N m_i (\mu_i - \mu)(\mu_i - \mu)^T$$

线性判别分析 LDA

LDA 求解多分类任务

同类样本接近，协方差矩阵 Σ_i 尽可能小

- 最小化 每个类别内 散度矩阵

$$S_{\omega} = \sum_{i=1}^N S_{\omega_i} \quad S_{\omega_i} = \sum_{x \in X_i} (x - \mu_i)(x - \mu_i)^T$$

异类样本远离，均值向量 μ_i 尽可能大

- 最大化 不同类别间 散度矩阵

$$S_b = S_t - S_{\omega} = \sum_{i=1}^N m_i (\mu_i - \mu)(\mu_i - \mu)^T$$

最大化全局 散度矩阵

$$S_t = S_b + S_{\omega} = \sum_{i=1}^m (x_i - \mu)(x_i - \mu)^T$$

线性判别分析 LDA

LDA 求解多分类任务

◆ 最大化全局 散度矩阵

$$S_t = S_b + S_\omega = \sum_{i=1}^m (x_i - \mu)(x_i - \mu)^T$$

◆ 转化为：广义特征值 求解

$$\max_W \frac{\text{tr}(W^T S_b W)}{\text{tr}(W^T S_\omega W)} \quad \Rightarrow \quad S_b W = \lambda S_\omega W$$

◆ ω 的闭式解

- $S_\omega^{-1} S_b$ 的前 d' 个最大广义特征值 所对应的 特征向量组成的矩阵

线性判别分析 LDA

LDA 求解多分类任务

◆ ω 的闭式解：

- $S_{\omega}^{-1}S_b$ 的 d' 个最大广义特征值所对应的特征向量矩阵

◆ 若将 ω 视为投影矩阵，则多分类LDA 将样本投影到 $N-1$ 维空间

◆ 可通过该投影 减小样本点的维数，且投影过程中 使用了类别信息。因此，LDA也常被视为一种经典的监督降维技术

线性模型优化总结

回归/分类模型优化的目标和参数的优化方法

- ◆ **线性回归**：最小二乘法，即最小化均方误差
求解：解析数学
- ◆ **对数几率回归**：最大化 样本分布似然
求解：凸优化梯度下降、牛顿法
- ◆ **线性判别分析**：投影空间内，最小(大)化 类内(间)散度；
求解：矩阵论、广义瑞利商

第三章：线性模型

1. 线性回归

- 线性回归、多元线性回归

2. 二分类任务

- 广义线性回归、线性判别分析

3. 多分类任务

- 一对一、一对其余、多对多

4. 类别不平衡问题

多分类学习

多分类学习方法

- ◆ 二分类学习方法 推广到 多分类
- ◆ 利用二分类学习器，解决多分类问题（常用）
 - 将多分类问题进行**拆分**，拆出的每个二分类任务训练对应一个二分类分类器
 - 对于每个二分类分类器的预测结果进行**集成**，以获得最终的多分类结果

多分类学习

多分类学习方法

- ◆ 利用二分类学习器，解决多分类问题（常用）
 - 将多分类问题拆分为若干个二分类任务
 - 集成二分类器的结果，并获得最终的多分类结果

□ 拆分策略

- 一对一： $N(N-1)/2$ 个二分类器
- 一对其余： N 个二分类器
- 多对多

多分类学习

一 对 一

一 对 其 余

拆分阶段

决策阶段

多分类学习

一对一

一对其余

拆分阶段

◆ N个类别两两配对

- $N(N-1)/2$ 二分类任务

决策阶段

◆ 新样本，提交给所有分类器预测

- $N(N-1)/2$ 个分类结果

◆ 投票产生最终分类结果

- 被预测最多的类别，作为最终类别

多分类学习

一对一

拆分阶段

- ◆ N个类别两两配对
 - $N(N-1)/2$ 二分类任务

决策阶段

- ◆ 新样本，提交给所有分类器预测
 - $N(N-1)/2$ 个分类结果
- ◆ 投票产生最终分类结果
 - 被预测最多的类别，作为最终类别

一对其余

拆分阶段

- ◆ 某一类作为正例，其他类作为反例
 - N 二分类任务

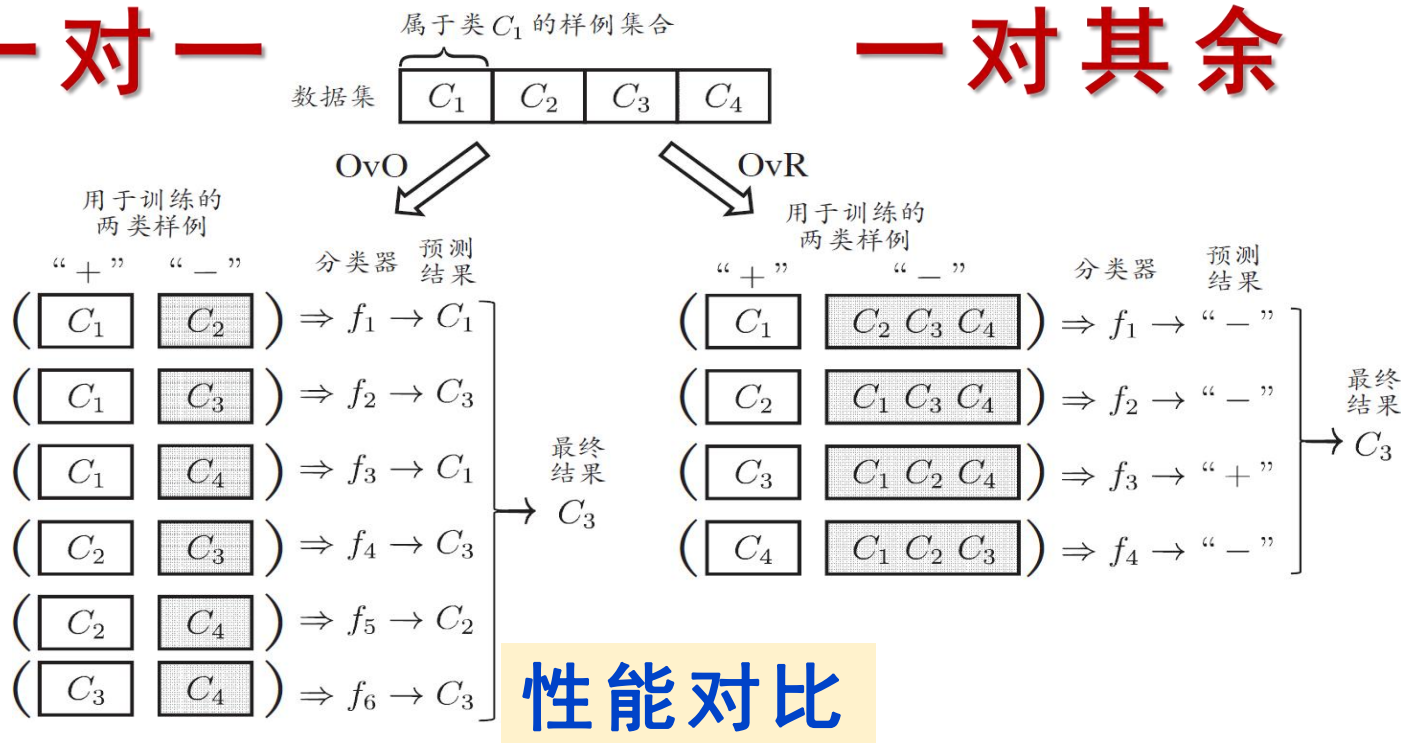
决策阶段

- ◆ 新样本，提交给所有分类器预测
 - N 个分类结果
- ◆ 比较各分类器预测 置信度
 - 置信度最大类别，作为最终类别

多分类学习

一对一

一对其余



◆ $N(N-1)/2$ 个分类器

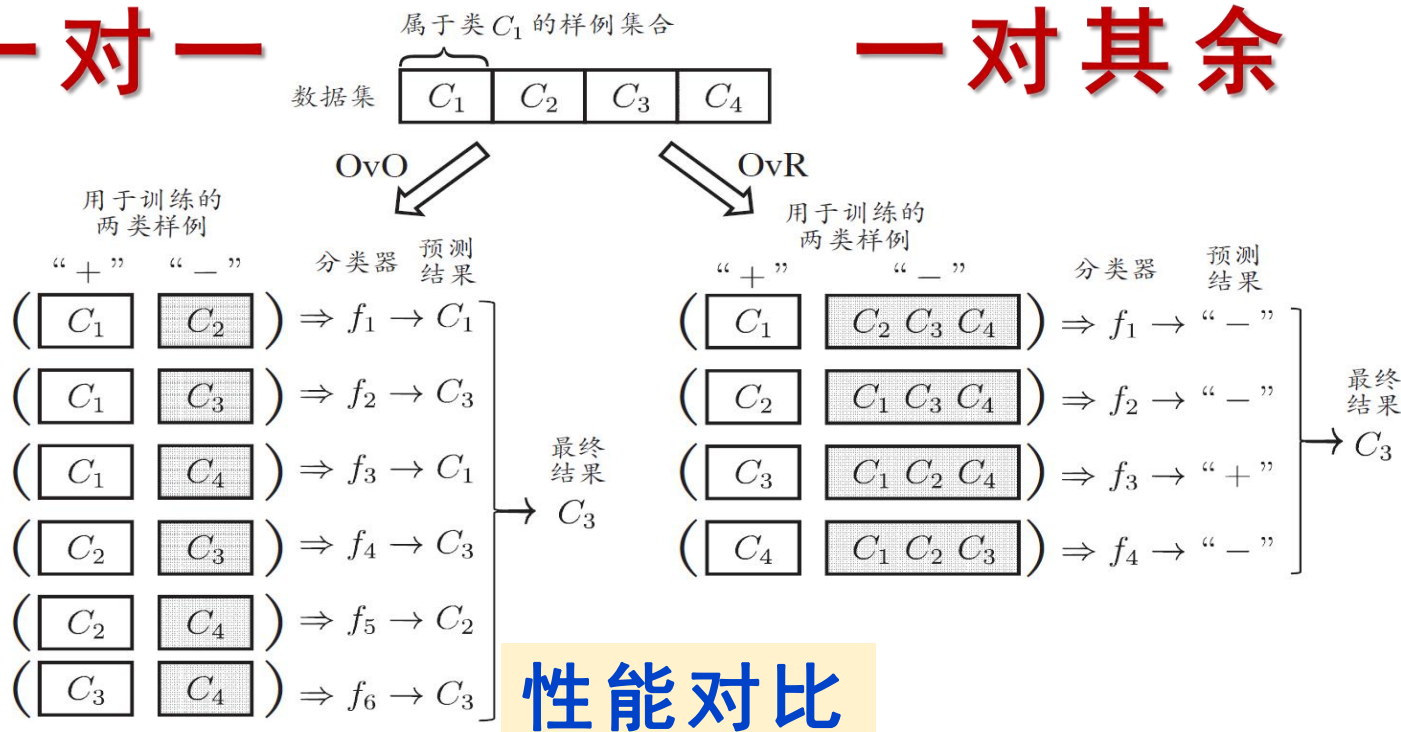
存储开销大和测试时间长

◆ 每个分类器训练，只用两个类样本，训练时间短

多分类学习

一对一

一对其余



◆ $N(N-1)/2$ 个分类器

存储开销**大**和测试时间**长**

◆ 每个分类器训练，只用**两个类样本**，训练时间**短**

◆ N 个分类器

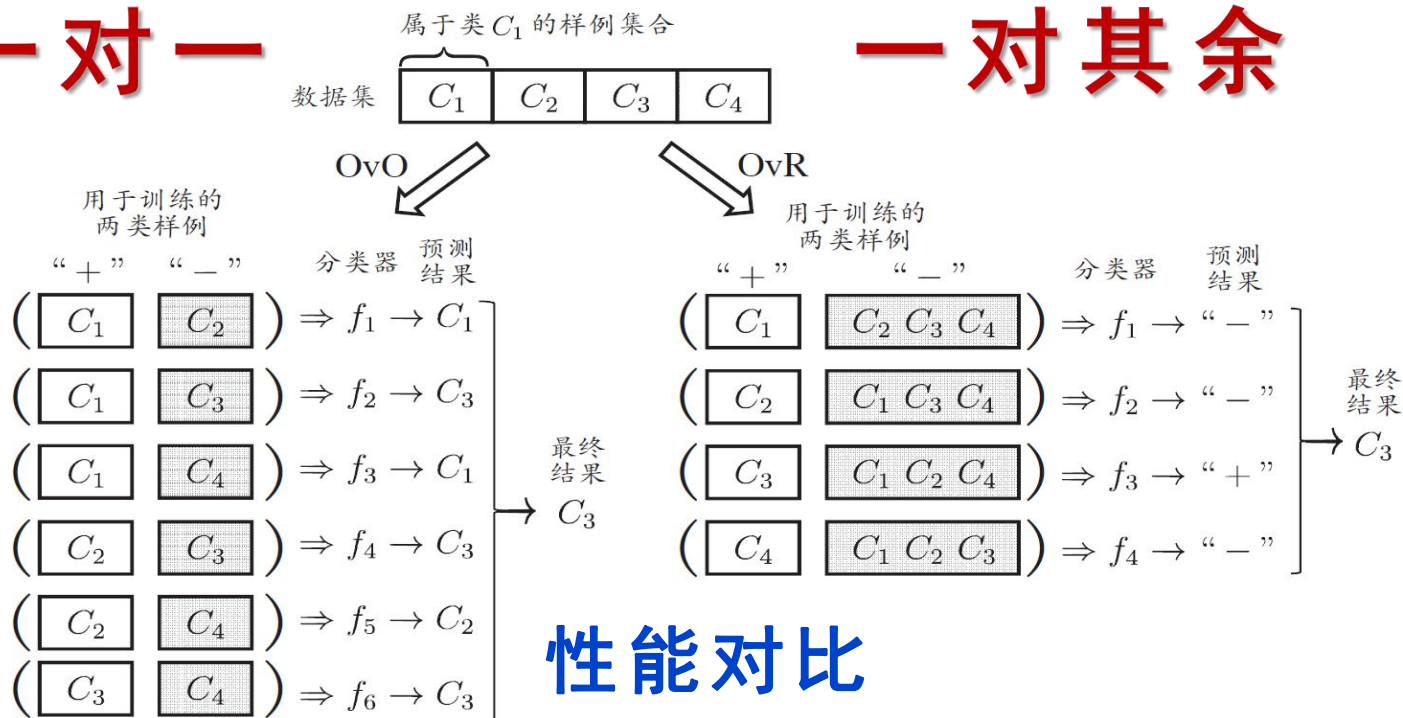
存储开销**小**和测试时间**短**

◆ 每个分类器训练，用到**全部训练样本**，训练时间**长**

多分类学习

一对一

一对其余



◆ **预测性能**: 取决于具体数据分布, 多数情况下两者差不多

◆ 不同类别的样本, **差异性较小时**, **一对其余**, 效果更好

第三章：线性模型

1. 线性回归

- 线性回归、多元线性回归

2. 二分类任务

- 广义线性回归、线性判别分析

3. 多分类任务

4. 类别不平衡问题

类别不平衡问题

- 前面的分类学习方法，都有一个共同的基本假设
不同类别 的训练样本 数目相当
- 如果不同类别的训练样本数目 稍有差别，通常影响不大
- 但是，若不同类别的 训练样本数目 差别很大，则会对学习过程造成困扰

类别不平衡问题

- 不同类别的训练样本数目差别很大，则会对学习过程造成困扰
- 现实分类学习任务中，经常会遇到类别不平衡

类别不平衡问题

- 不同类别的训练样本数目差别很大，则会对学习过程造成困扰
- 现实分类学习任务中，经常会遇到类别不平衡
 - 例如：公安系统中，犯罪分子的甄别问题：有998个反例（合法公民），但正例只有2个（犯罪分子）
 - 那么，学习方法，只需返回一个永远将新样本预测为反例（合法公民）的学习器，就能达到99.8%的精度
 - 然而，这样的学习器往往没有价值，因为它不能预测出任何正例

类别不平衡问题

- 不同类别的训练样本数目差别很大，则会对学习过程造成困扰
- 现实分类学习任务中，经常会遇到类别不平衡
 - 通过拆分法，解决多分类问题时，
即使 原始问题中，不同类别的训练样本数目相当，
使用一对多、多对多策略后，产生的二分类任务
仍可能出现类别不平衡现象

类别不平衡问题

解决方式：再缩放

- ◆ 欠采样：去除一些反例
- ◆ 过采样：增加一些正例
- ◆ 阈值移动

类别不平衡问题

解决方式：再缩放

◆ 阈值移动

- 对于线性分类器，用 $y = \omega^T x + b$ 对新样本进行分类
 - y ：表达了正例的可能性。通常 $y > 0.5$ ，判别为正例，否则为反例。
 - 几率 $\frac{y}{1-y}$ ：反映了正例可能性与反例可能性之比值

类别不平衡问题

解决方式：再缩放

◆ 阈值移动

- 对于线性分类器，用 $y = \omega^T x + b$ 对新样本进行分类
 - 分类器的预测几率 > 观测几率，判为正例，
即 $\frac{y}{1-y} > \frac{m^+}{m^-}$ 预测为正例

其中， m^+ 为正例样本个数， m^- 为反例样本个数

正例预测

类别平衡

$$\frac{y}{1-y} > 1$$

类别不平衡

$$\frac{y}{1-y} > \frac{m^+}{m^-}$$

第三章：线性模型

1. 线性回归

- 线性回归、多元线性回归

2. 二分类任务

- 广义线性回归、线性判别分析

3. 多分类任务

4. 类别不平衡问题

第三章：线性模型总结

1. **线性回归** 目的：学得一个线性模型以尽可能准确地预测实值输出标记
2. **最小二乘法**：试图找到一条直线，使所有样本到直线上的欧氏距离之和最小
3. **线性判别分析 LDA**：是一种经典的线性学习方法。
 - ✓ 给定训练样本集，设法将样本投影到一条直线上，使得 **同类样本的投影点尽可能接近**，**异类样本的投影点尽可能远离**。
 - ✓ 在对新样本进行分类时，将其投影到同样的这条直线上，再根据投影点的位置来确定新样本的类别。
4. **类别不平衡问题**：不同类别训练样本数相差很大情况（正类为小类）